

03. شجرة B واستعادة البيانات بعد الأعطال

(B-Tree & Crash Recovery)

3.1 شجرة B كشجرة n-أرية متوازنة

(Height-Balanced Tree)

العديد من الأشجار الثنائية العملية، مثل شجرة AVL أو شجرة RB (الحمراء-السوداء)، تسمى أشجار متوازنة الارتفاع، بمعنى أن ارتفاع الشجرة (من الجذر إلى الأوراق) محدود بـ $O(\log N)$ ، لذلك البحث يكون $O(\log N)$.

شجرة B أيضاً متوازنة الارتفاع؛ الارتفاع هو نفسه لجميع العقد الورقية.


شرح المصطلحات:

- **Height (الارتفاع):** عدد المستويات من الجذر إلى الأوراق
- **Balanced (متوازن):** جميع المسارات لها نفس الطول
- **AVL Tree:** شجرة ثنائية بحث متوازنة تلقائياً
- **(RB Tree (Red-Black Tree):** شجرة حمراء-سوداء متوازنة

(Generalizing Binary Trees)

الأشجار n-أرية يمكن تعديلها من الأشجار الثنائية (والعكس). مثال على ذلك شجرة 2-3-4، وهي شجرة B حيث كل عقدة يمكن أن يكون لها 2 أو 3 أو 4 أطفال. شجرة 2-3-4 مكافئة لشجرة RB.

تصور شجرة B+tree من مستويين لسلسل مرتب [12, 11, 9, 6, 4, 3, 2, 1]:



شرح: في شجرة B+tree، فقط العقد الورقية تحتوي على القيم، والمفاتيح مكررة في العقد الداخلية للإشارة إلى نطاق المفاتيح في الشجرة الفرعية.

في هذا المثال، العقدة [1, 4, 9] تشير إلى أن أشجارها الفرعية الثلاثة موجودة ضمن الفترات:

- [4, 1]: من 1 إلى 4 (لا تشمل 4)
- [9, 4]: من 4 إلى 9 (لا تشمل 9)

- $(\infty, 9]$: من 9 إلى ما لا نهاية

ومع ذلك، نحتاج فقط إلى مفاتيح لثلاث فترات، لذلك يمكن حذف المفتاح الأول (1) وتصبح الفترات الثلاث:

- $(4, \infty)$: من سالب ما لا نهاية إلى 4
 - $[9, 4]$: من 4 إلى 9
 - $[\infty, 9]$: من 9 إلى ما لا نهاية
-

3.2 شجرة B كمصفوفات متداخلة

مصفوفات متداخلة من مستويين (Two-Level Nested Arrays)

بدون معرفة تفاصيل شجرة RB أو شجرة 2-3-4، يمكن فهم شجرة B من المصفوفات المرتبة.

المشكلة في المصفوفات المرتبة: التحديث (O(N)) مكلف جداً!

الحل: إذا قسمنا المصفوفة إلى m مصفوفة أصغر غير متداخلة، يصبح التحديث $O(N/m)$.

لكن يجب علينا معرفة أي مصفوفة صغيرة نحدث/نستعمل أولاً. لذلك نحتاج مصفوفة مرتبة أخرى من المراجع إلى المصفوفات الأصغر
- هذه هي العقد الداخلية في $B+tree$.

$[[9,11,12],[4,6],[1,2,3]]$

التكلفة:

- البحث لا يزال $O(\log N)$ مع بحثين ثانيين
- إذا اخترنا $N = \sqrt{m}$ ، يصبح التحديث $O(\sqrt{N})$

مثال عملي:

- لفرض لدينا 100 عنصر:
- مصفوفة واحدة: التحديث $O(100)$
- 10 مصفوفات \times 10 عناصر: التحديث $O(10)$

مستويات متعددة من المصفوفات المتداخلة

$O(\sqrt{N})$ غير مقبول لقواعد البيانات، لكن إذا أضفنا مستويات أكثر بتقسيم المصفوفات أكثر، تتحسن التكلفة أكثر.

لفترض أننا نستمر في تقسيم المستويات حتى تصبح جميع المصفوفات لا تزيد عن ثابت s :

- تنتهي بـ $O(\log(N/s))$ مستويات
- تكلفة البحث: $O(\log(\log(N/s)) + \log(s)) = O(\log \log N)$

للإدراج والحذف: بعد إيجاد العقدة الورقية، تحديث العقدة الورقية يكون ثابتاً $O(s)$ في معظم الأحيان.

المشكلة المتبقية: الحفاظ على الثوابت التي تقول:

- العقد ليس أكبر من s
- العقد ليس فارغاً

3.3 صيانة شجرة B+tree



3 ثوابت يجب الحفاظ عليها عند تحديث B+tree

1. نفس الارتفاع لجميع العقد الورقية
2. حجم العقدة محدود بثابت
3. العقدة ليست فارغة

(Growing by Splitting) تنمية شجرة B بتقسيم العقد


الثابت الثاني ينتهي بالإدراج في عقدة ورقية، ويُستعاد ب التقسيم العقدة إلى عقد أصغر.

مثال على التقسيم:




بعد تقسيم عقدة ورقية، تحصل العقدة الأم على فرع جديد، مما قد يتتجاوز أيضاً حد الحجم، لذلك قد تحتاج هي أيضاً إلى التقسيم.

انتشار التقسيم إلى الجذر:



L1 L2 L6



تقسيم العقدة يمكن أن ينتشر إلى عقدة الجذر، مما يزيد الارتفاع بمقدار 1.

هذا يحفظ الثابت الأول، لأن جميع الأوراق تكتسب ارتفاعاً بمقدار 1 في نفس الوقت.

تقليل شجرة B بدمج العقد (Shrinking by Merging)

الحذف قد يؤدي إلى عقد فارغة. الثابت الثالث يُستعاد بدمج العقد الفارغة في عقدة شقيقة.

الدمج عكس التقسيم:

- يمكن أن ينتشر أيضاً إلى عقدة الجذر
- يمكن أن ينخفض ارتفاع الشجرة

تحسين: يمكن القيام بالدمج مبكراً لتقليص المساحة المهدورة - يمكنك دمج عقدة غير فارغة عندما يصل حجمها إلى حد أدنى.

3.4 شجرة B على القرص

يمكنك الآن كتابة كود شجرة B في الذاكرة باستخدام هذه المبادئ. لكن شجرة B على القرص تتطلب اعتبارات إضافية.

التخصيص القائم على الكتل (Block-Based Allocation)

التفصيل المفقود: كيف نحدد حجم العقدة؟

في الذاكرة:

- يمكنك تحديد العدد الأقصى للمفاتيح في عقدة
- حجم العقدة بالبيانات ليس مصدر فلاق
- يمكنك تخصيص أي عدد من البيانات حسب الحاجة

على القرص:

- لا يوجد garbage collector أو malloc/free
- تخصيص المساحة وإعادة الاستخدام متروك لنا بالكامل

الحل: إعادة استخدام المساحة يمكن أن تتم بقائمة حرة (free list) إذا كانت جميع التخصيصات بنفس الحجم. لذلك، جميع عقد شجرة B لها نفس الحجم.

شجرة B بـ **Copy-on-Write** للتحديثات الآمنة

رأينا 3 طرق مقاومة للأعطال لتحديث بيانات الفرع:

1. إعادة تسمية الملفات
2. السجلات (Logs)
3. أشجار LSM

الدرس: لا تدمر أي بيانات قديمة أثناء التحديث!


تطبيق الفكرة على الأشجار: اصنع نسخة من العقدة وعدل النسخة بدلاً من الأصل.

كيف يعمل **Copy-on-Write**؟

الشجرة الأصلية:



بعد تحديث C:



الأحرف الكبيرة (*) = عقد منسوبة
الأحرف الصغيرة = عقد مشتركة (لم تتغير)

العملية:

1. الإدراج أو الحذف يبدأ عند عقدة ورقة
2. بعد عمل نسخة مع التعديل، يجب تحديث العقدة الأم للإشارة إلى العقدة الجديدة
3. هذا أيضاً يتم على نسخة من العقدة الأم
4. النسخ ينشر إلى عقدة الجذر، مما ينتج جذر شجرة جديد

النتيجة:

- الشجرة الأصلية تبقى سليمة ويمكن الوصول إليها من الجذر القديم
- الجذر الجديد، مع النسخ المحدثة طوال الطريق إلى الورقة، يشارك جميع العقد الأخرى مع الشجرة الأصلية

المصطلحات البديلة:

- **Immutable** (غير قابل للتغيير)
- **Append-only** (إضافة فقط) - ليس حرفيًا
- **Persistent** (مستمر) - غير متعلق بالمتانة

تحذير: مصطلحات قواعد البيانات ليس لها معاني متسقة! 

مشكلتان متبقيتان لـ **Copy-on-Write B-tree**:

1. كيف نجد جذر الشجرة؟ يتغير بعد كل تحديث!

◦ مشكلة الأمان من الأعطال تُخترل إلى تحديث مؤشر واحد (سنحلها لاحقًا)

2. كيف نعيد استخدام العقد من النسخ القديمة؟

◦ هذه وظيفة القائمة الحرة (free list)

مزايا **Copy-on-Write B-tree**

1. عزل اللقطات (**Snapshot Isolation**) مجاناً:

- المعاملة تبدأ بنسخة من الشجرة
- لن ترى التغييرات من النسخ الأخرى

2. استعادة البيانات بدون جهد:

◦ فقط استخدم آخر نسخة قديمة

3. نموذج التزامن متعدد القراء-كاتب واحد:

◦ القراء لا يحجبون الكاتب

مثال عملي:

النسخة 1: [أحمد:100, سارة:200]

النسخة 2: [أحمد:100, سارة:200, علي:300] ← إضافة علي

النسخة 3: [أحمد:150, سارة:200, علي:300] ← تحديث أحمد

القارئ 1 يرى النسخة 1

القارئ 2 يرى النسخة 2

الكاتب يعمل على النسخة 3

البديل: التحديث في المكان مع الكتابة المزدوجة (**Double-Write**)

بينما استعادة البيانات واضحة في هيكل **Copy-on-Write**, قد تكون غير مرغوب فيها بسبب تضخم الكتابة المرتفع.

المشكلة:

- كل تحديث ينسخ المسار الكامل $O(\log N)$
- معظم التحديثات في المكان تلمس عقدة ورقية واحدة فقط

الحل: Double-Write

من الممكن القيام بتحديثات في المكان مع استعادة البيانات بدون Copy-on-Write:
الخطوات:

1 حفظ نسخة من جميع العقد المحدثة في مكان ما
| a=2 b=4 | → نسخة: | a=1 b=2 |

2 fsync النسخ المحفوظة
(يمكن الرد على العميل عند هذه النقطة)

3 حدث هيكل البيانات فعلياً في المكان

4 fsync التحديثات

ماذا بعد العطل؟

الحالة بعد العطل:
| a=2 b=4 | + | ??????? |
البيانات (سيئة) النسخة (جيدة)

الاستعادة: طبق النسخة المحفوظة
| a=2 b=4 | + | a=2 b=4 |
البيانات (جديدة) عديمة الفائدة الآن

بعد العطل، قد يكون هيكل البيانات محدثاً جزئياً، لكننا لا نعرف حقاً ما نفعه هو تطبيق النسخ المحفوظة بشكل أعمى، بحيث ينتهي هيكل البيانات بالحالة المحدثة، بغض النظر عن الحالة الحالية.

المصطلح: النسخ المحدثة المحفوظة تسمى double-write في مصطلحات MySQL.

ماذا لو كانت الكتابة المزدوجة تالفة؟

يتم التعامل معها بنفس طريقة السجلات: Checksum (المجموع الاختباري)

- إذا اكتشف Checksum كتابة مزدوجة سيئة: تجاهلها

○ إنها قبل أول fsync، لذلك البيانات الرئيسية في حالة جيدة وقديمة

- إذا كانت الكتابة المزدوجة جيدة: تطبيقها سينتاج دائمًا بيانات رئيسية جيدة

التسجيل الفيزيائي (Physical Logging)

بعض قواعد البيانات تخزن فعليًا الكتابات المزدوجة في السجلات، يُسمى **physical logging**. نوعان من التسجيل:

1. Logical Logging (تسجيل منطقي):

- يصف عمليات عالية المستوى مثل "إدراج مفتاح"
- يمكن تطبيقه فقط عندما تكون قاعدة البيانات في حالة جيدة

2. Physical Logging (تسجيل فيزيائي):

- تحديثات صفحات القرص منخفضة المستوى
- مفيد للاستعادة لأنه يعمل مع أي حالة

مبدأ استعادة البيانات (Crash Recovery Principle)

مقارنة :Copy-on-Write مع Double-Write

:Double-Write

- يجعل التحديثات **Idempotent** (متكافئة)
- قاعدة البيانات يمكنها إعادة محاولة التحديث بتطبيق النسخ المحفوظة
- تطبيق العملية مرتين = تطبيقها مرة واحدة

:Copy-on-Write

- يبدل كل شيء للنسخة الجديدة **Atomically** (ذرياً)
- الكل أو لا شيء

الأفكار الأساسية:

:Double-Write

- يضمن معلومات كافية لإنتاج النسخة الجديدة

:Copy-on-Write

- يضمن الحفاظ على النسخة القديمة

الطريقة الثالثة:

ماذا لو حفظنا العقد الأصلية بدلاً من العقد المحدثة مع Double-Write؟

- تستعيد إلى النسخة القديمة مثل Copy-on-Write
- يمكننا دمج الطرق الثلاث في فكرة واحدة:

المبدأ الموحد:

هناك معلومات كافية للحصول على الحالة القديمة أو الحالة الجديدة في أي نقطة

ملاحظة: بعض النسخ مطلوب دائماً، لذلك العقد الأكبر أبطأ في التحديث.

اختيارنا: سنستخدم Copy-on-Write لأنها أبسط، لكن يمكنك الانحراف هنا.

3.5 ما تعلمناه

B+tree مبادئ

شجرة n-أريية: حجم العقدة محدود بثابت ✓

نفس الارتفاع لجميع الأوراق: شجرة متوازنة ✓

التقسيم والدمج: للإدراج والحذف ✓

هياكل البيانات القائمة على الفراغ:

Copy-on-Write: لا تدمر البيانات القديمة ✓

Double-Write: للاستعادة من الأعطال ✓

خطوات الترميز *

يمكننا البدء في الترميز الآن! 3 خطوات لإنشاء KV مستمر بناءً على B+tree:

1. ترميز هيكل بيانات B+tree
2. نقل B+tree إلى الفراغ
3. إضافة قائمة حرة (Free List)

ملخص المقارنة



Double-Write	Copy-on-Write	الميزة
حفظ النسخة الجديدة	حفظ النسخة القديمة	الفكرة
أعد تطبيق التحديثات	استخدم النسخة القديمة	الاستعادة
منخفض ($O(1)$)	مرتفع ($O(\log N)$)	تضخم الكتابة
أكثر تعقيداً	أبسط ✓	البساطة
يحتاج عمل إضافي	مجاناً ✓	Snapshot Isolation
MySQL InnoDB	SQLite, LMDB	الاستخدام

نصائح عملية

متى تستخدم **?B+tree**

- قراءات كثيرة، كتابات قليلة
- نecessity لـ range queries
- استعلامات OLTP

متى تستخدم **?Copy-on-Write**

- تحتاج Snapshot Isolation
- استعادة بيانات سهلة
- تزامن متعدد القراء

متى تستخدم **?Double-Write**

- تقليل تضخم الكتابة مهم
- أداء الكتابة حرج
- لديك خبرة في إدارة التعقيد